

Actividad 2. Análisis exploratorio inicial en Python

Reto StayData Lab — base Airbnb price prediction

1. Descripción general de la base

El archivo entregado es un libro de Excel con una sola hoja ("in"). Antes de poder analizarlo fue necesario reconstruirlo: el CSV completo viene contenido en una sola columna y los registros que rebasan el límite de 32,767 caracteres por celda se derraman en columnas adicionales. Reconstruidos los registros se obtienen 74,080 filas válidas y 29 columnas —19 registros con comillas mal cerradas quedaron fuera, el 0.03 % del total—, sin identificadores repetidos ni filas idénticas. El archivo original no se modificó en ningún momento: la lectura es de solo lectura y el resultado se almacena aparte en formato Parquet para acelerar las siguientes corridas. La base cubre seis ciudades de Estados Unidos: Nueva York (32,334 anuncios), Los Ángeles (22,443), San Francisco (6,431), Washington D. C. (5,686), Chicago (3,719) y Boston (3,467), con fechas de reseñas entre 2008 y octubre de 2017.

2. Resumen de variables principales

La variable objetivo es **log_price**, el logaritmo natural del precio por noche en dólares: media 4.78, mediana 4.71, mínimo 0 y máximo 7.60. Reexpresada en escala original, la mediana es de USD 111 por noche, el rango intercuartílico va de USD 75 a USD 185, el 90 % central se ubica entre USD 40 y USD 425, y el máximo es exactamente USD 1,999. Entre las numéricas, **accommodates** tiene mediana 2 y máximo 16; **bathrooms**, **bedrooms** y **beds** tienen mediana 1; **number_of_reviews** tiene mediana 6 y máximo 605; y **review_scores_rating** promedia 94.1 con mediana 96, aunque solo está disponible para 57,366 anuncios. Entre las categóricas, **room_type** distingue Entire home/apt (41,299), Private room (30,621) y Shared room (2,160); **property_type** tiene 35 niveles dominados por Apartment (66 %); **cancellation_policy** concentra 32,363 anuncios en "strict"; **bed_type** es casi constante (97.2 % "Real Bed"); **cleaning_fee** es verdadero en 54,385 anuncios; **instant_bookable** solo en 19,440 (26 %); y **neighbourhood** alcanza 619 niveles distintos.

3. Hallazgos exploratorios iniciales

- El precio en dólares está fuertemente sesgado a la derecha, mientras que **log_price** se aproxima a una distribución simétrica: esto respalda la decisión de la base de entregar el precio en escala logarítmica.
- Las variables de tamaño son las más asociadas al precio. La correlación de Spearman con **log_price** es de 0.589 para **accommodates**, 0.481 para **beds**, 0.408 para **bedrooms** y 0.283 para **bathrooms**.
- Las variables de reseñas muestran una asociación casi nula: 0.085 para **review_scores_rating** y -0.033 para **number_of_reviews**. El precio mediano sube de USD 98 en calificaciones de 80 o menos a USD 119 en las de 95 o más, pero el 47.4 % de los anuncios ya está en 95 o más, por lo que la variable discrimina poco.
- Por tipo de espacio, el precio mediano es de USD 160 en propiedad completa, USD 75 en habitación privada y USD 45 en habitación compartida.
- Por ciudad, el precio mediano va de USD 99 en Chicago y USD 100 en Los Ángeles a USD 165 en San Francisco, con Boston (USD 136), Washington D. C. (USD 125) y Nueva York (USD 105) en posiciones intermedias.
- Dentro de Nueva York, y considerando solo barrios con al menos 100 anuncios, el precio mediano va de USD 55 en Elmhurst a USD 250 en Tribeca: la variación dentro de una misma ciudad es mayor que la variación entre ciudades.
- Las políticas y cargos también se mueven con el precio: mediana de USD 129 con cancelación estricta frente a USD 99 con política flexible, y USD 120 cuando se cobra tarifa de limpieza frente a USD 95 cuando no. La reserva inmediata muestra una diferencia menor y en sentido inverso (USD 105 frente a USD 115).

Todas estas comparaciones son descriptivas y no controlan por otras variables; ninguna debe leerse todavía como un efecto sobre el precio.

4. Anomalías y problemas detectados

Se ejecutaron siete reglas de calidad automatizadas. Ninguna modifica la base: solo documentan el problema y el tratamiento propuesto para la Actividad 3.

Problema	Variables	Observado	Tratamiento propuesto
Estructura del archivo	Todas	El CSV viene dentro de una sola columna de Excel y los registros largos se derraman en columnas extra; 19 registros (0.03 %) tienen comillas mal cerradas y se omiten	Reconstruir el registro por fila antes de analizar; documentar los omitidos
Faltantes altos	host_response_rate (24.7 %), review_scores_rating (22.6 %), first_review y last_review (21.4 %)	Coinciden con los 15,811 anuncios que no han recibido ninguna reseña	Bandera "sin reseñas" e imputación aparte; no eliminar filas

Problema	Variables	Observado	Tratamiento propuesto
Faltantes moderados	thumbnail_url (11.1 %), neighbourhood (9.3 %), zipcode (1.3 %), bathrooms, bedrooms, beds y campos de anfitrión (< 0.3 %)	El faltante de neighbourhood se concentra en Los Ángeles	Categoría "Desconocido" en texto y mediana por ciudad en numéricas
Precios extremos y posible censura	log_price	160 anuncios de USD 20 o menos (mínimo USD 1), 668 de USD 1,000 o más, máximo exacto de USD 1,999 y 537 con menos de USD 10 por huésped	Revisar ambas colas, documentar el tope y evaluar acotar los percentiles 1 y 99
Ceros ambiguos	bedrooms (6,713), bathrooms (198), beds (4)	bedrooms = 0 corresponde a estudios; los ceros en bathrooms y beds son dudosos	Marcar estudios con bandera y revisar los otros ceros caso por caso
Formatos inconsistentes	zipcode, host_response_rate, cleaning_fee	8,875 códigos postales con formato "94117.0"; la tasa de respuesta conserva el signo "%"; cleaning_fee usa True/False y el resto de booleanas t/f	Normalizar a cinco dígitos, convertir a decimal y unificar booleanas a 0/1
Alta cardinalidad	neighbourhood (619), zipcode (767), property_type (35)	Una codificación uno-a-uno generaría cientos de columnas	Agrupar niveles raros en "Otros" y codificar por frecuencia dentro de cada ciudad
Texto sin estructura	amenities, description, name	amenities tiene 17.6 elementos en promedio y 585 listas vacías	Convertir los servicios más frecuentes en indicadores binarios
Duplicados	id y registros completos	0 identificadores repetidos y 0 filas idénticas	Sin acción; revisar de nuevo tras la limpieza

5. Interpretación de las visualizaciones

Figura 1 • Distribución del precio y de log_price. Muestra una cola derecha larga en dólares, con la mayoría de los anuncios concentrados entre USD 50 y USD 200 y una mediana de USD 111, frente a una distribución casi simétrica en escala logarítmica. Sugiere que el logaritmo es la escala adecuada para trabajar. Precaución: el histograma en dólares está recortado en el percentil 99 para poder verse, así que oculta visualmente los 668 anuncios de USD 1,000 o más que sí siguen en la base.

Figura 2 • Precio por tipo de espacio. Las tres medianas están claramente separadas (USD 160, 75 y 45) y las cajas apenas se traslapan entre propiedad completa y habitación privada. Sugiere que room_type ordena el mercado en tres niveles de precio. Precaución: la habitación compartida solo tiene 2,160 anuncios frente a 41,299 de propiedad completa, y la comparación no controla por capacidad ni por ciudad.

Figura 3 • Precio mediano por capacidad y tipo de espacio. El precio mediano crece de forma sostenida con accommodates en propiedad completa (de USD 110 a USD 360), con una pendiente más plana en habitación privada y prácticamente nula en habitación compartida. Sugiere que el efecto de la capacidad depende del tipo de espacio. Precaución: solo se grafican grupos con al menos 30 anuncios; los tamaños grandes en habitaciones privadas y compartidas son escasos y su mediana es inestable.

Figura 4 • Precio mediano por ciudad. San Francisco encabeza con USD 165 y Chicago cierra con USD 99, una diferencia de 1.7 veces entre extremos. Sugiere que la ciudad es una variable de control necesaria. Precaución: el volumen es muy desigual —Nueva York aporta el 44 % de los anuncios y Boston menos del 5 %—, y la mediana de una ciudad mezcla barrios muy distintos entre sí.

Figura 5 • Valores faltantes por variable. Cuatro variables superan el 21 % de faltantes y todas pertenecen al bloque de reseñas y respuesta del anfitrión. Sugiere que el faltante no es aleatorio, sino que identifica a los anuncios sin actividad. Precaución: imputar esas variables con la media introduciría anuncios "con reseñas" que no existen; el faltante debe conservarse como información.

6. Relación con las preguntas analíticas de la Actividad 1

Pregunta inicial	Qué se observó en esta etapa	Qué falta preparar
Distribución del precio entre ciudades	Medianas de USD 99 a USD 165; la ciudad separa niveles de precio pero no explica la dispersión interna	Descomponer la varianza dentro y entre ciudades
Diferencia por room_type controlando capacidad	Las tres medianas se separan y la brecha se mantiene al abrir por accommodates (Figura 3)	Contrastar formalmente con capacidad y ciudad fijas
Relación entre capacidad, tamaño y precio	Es la asociación más fuerte encontrada (Spearman 0.589 con accommodates)	Revisar rendimientos decrecientes y tratar bedrooms = 0
Papel de las reseñas y la calificación	Asociación casi nula y calificación muy concentrada (47.4 % en 95 o más)	Definir el tratamiento de los 15,811 anuncios sin reseñas
Barrios y zonas dentro de cada ciudad	En Nueva York el rango va de USD 55 a USD 250 entre barrios comparables	Agrupar los 619 barrios y normalizar zipcode
Políticas, reserva inmediata y amenities	Diferencias visibles por cancellation_policy y cleaning_fee; amenities aún sin explotar	Extraer los servicios frecuentes como variables binarias

7. Ejecución del archivo técnico y repositorio

El proyecto está organizado en capas (dominio, aplicación e infraestructura) con inyección de dependencias en un único punto de composición; los comentarios y docstrings están en inglés. Para reproducirlo basta colocar el archivo original en `data/raw/airbnb_price_prediction.xlsx` y ejecutar, dentro del contenedor, `"docker compose run --rm eda"` para el análisis completo o `"docker compose up lab"` para abrir el notebook en el puerto 8888. Sin Docker: instalar `requirements.txt`, definir `PYTHONPATH=src` y ejecutar `"python -m staydata_eda.main"` o abrir `notebooks/01_exploratory_analysis.ipynb`. Las pruebas unitarias se corren con `"pytest tests -q"`. El notebook se ejecuta de inicio a fin sin errores y escribe las cinco figuras en `reports/figures/`.

Repositorio: <https://github.com/<usuario>/staydata-airbnb-eda> (sustituir por la URL propia tras el push; el historial sigue Conventional Commits).